Study Coach

Documentazione di Progetto

Apprendimento socratico su materiale universitario, con RAG

SVILUPPATORI

Diabi Mohamed Zakaria

Gouaiche Kamal

DOCUMENTAZIONE

15 agosto 2026

Indice

1. Descrizione del progetto 2

2. Architettura del progetto 2

3. Decisioni prese nel progetto 4

4. Tecnologie e librerie usate 5

5. Processo di implementazione 6

6. Percorsi e configurazione di default 7

7. Funzionalità implementate 8

8. Struttura delle cartelle 10

9. Testing 10

10. Limitazioni note e possibili sviluppi futuri 11

11. Divisione dei contributi (Agent) 11

12. Utilizzo di intelligenza artificiale 12

1 Descrizione del progetto

Study Coach è un'applicazione di supporto allo studio universitario che trasforma il materiale didattico (PDF) caricato dallo studente in un percorso di apprendimento interattivo, basato sul **metodo socratico** invece che sulla semplice correzione domanda/risposta.

> **L'idea di fondo:** invece di dare subito la risposta corretta, il sistema fa ragionare lo studente attraverso domande guida, poi mostra dove ha sbagliato e fornisce la risposta corretta e migliorata — il tutto ancorato esclusivamente al materiale caricato (RAG, *Retrieval-Augmented Generation*), per evitare risposte generiche o allucinate.

Il progetto offre due modalità di interazione:

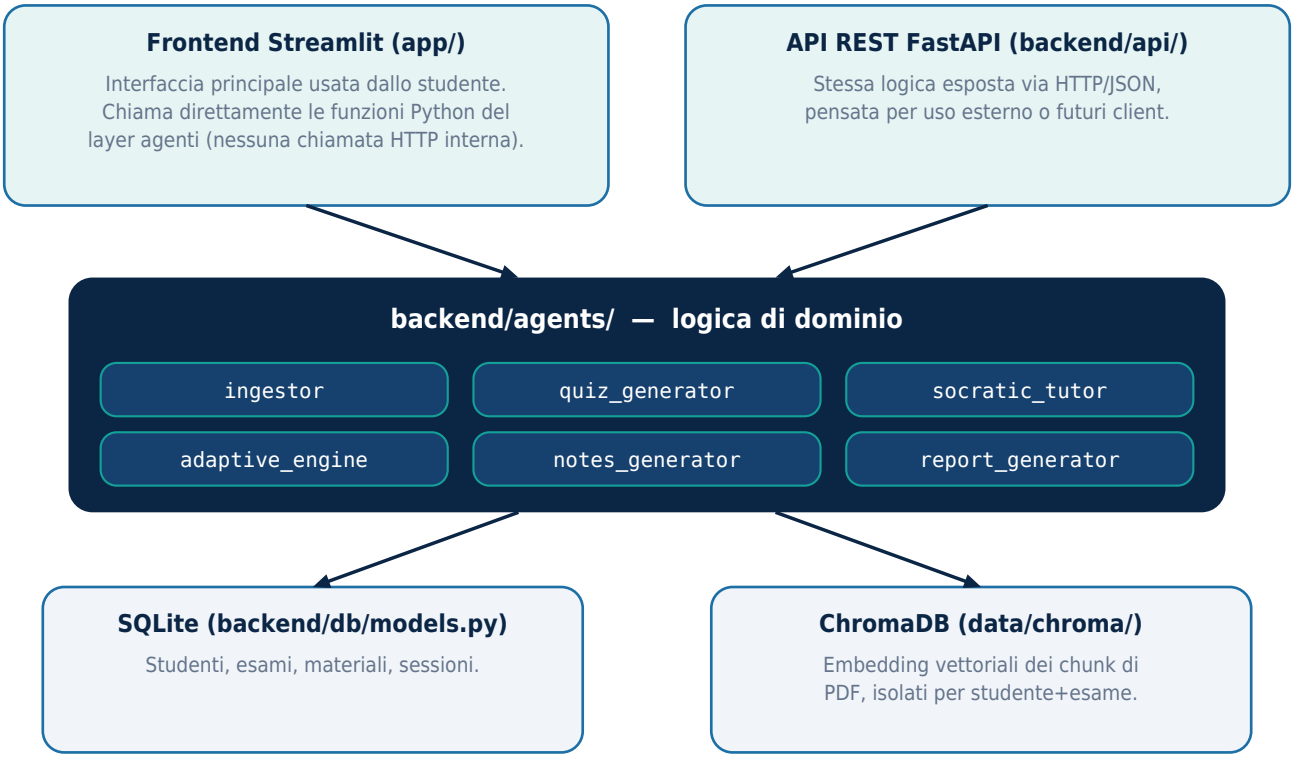
Sessione quiz strutturata
il sistema genera N domande a risposta aperta dal materiale caricato e guida lo studente attraverso ciascuna con il loop socratico.

Chatbot dubbi libero
lo studente scrive un dubbio proprio (non un quiz) e il tutor risponde con una domanda socratica invece di dare subito la soluzione.

Al termine di ogni sessione viene generato un **report** (Markdown + PDF) con punteggio, argomenti deboli/forti e sintesi, e sono disponibili **appunti sintetici** generati dal materiale o dal log della sessione.

2 Architettura del progetto

Il progetto è organizzato in tre macro-livelli, con una netta separazione tra logica di dominio e interfacce:



Componenti principali

> Le chiamate agli agenti Groq sono sincrone e basate su system prompt e contesto del singolo task. Il flusso corrente non configura tool/function calling, ricerca web, esecuzione di codice o cronologia conversazionale.

Livello	Cartella	Ruolo
Frontend	`app/pages/*.py`	Pagine Streamlit (login, upload, exam, session, chat, history). Chiamano direttamente le funzioni di `backend/agents` — nessuna chiamata HTTP interna.
API REST	`backend/api/*.py`	Router FastAPI (auth, exams, sessions) che espone la stessa logica via HTTP/JSON, con stato dei tutor/engine attivi tenuto in memoria di processo.
Logica di dominio	`backend/agents/*.py`	Agenti indipendenti dall'interfaccia: ingestion RAG, generazione quiz, tutor socratico, motore adattivo, generazione appunti/report.
Persistenza	`backend/db/models.py`	Modelli SQLAlchemy (Student, Exam, Material, Session) su SQLite (`data/study_coach.db`).
Contratti API	`backend/models/schemas.py`	Modelli Pydantic per richieste/risposte dell'API REST.
Vector store	ChromaDB (`data/chroma/`)	Una collection isolata per ogni coppia student_id+exam_id (`student_{id}_exam_{id}`).

Flusso dati principale

1. Lo studente carica un PDF → `ingestor.py` estrae il testo, lo divide in chunk (500 parole, overlap 50) e li indicizza in ChromaDB con embedding locali.
2. `quiz_generator.py` recupera i chunk più rilevanti (RAG) e chiede a un agente LLM (Groq) di generare N domande aperte, calibrate su tre livelli di difficoltà.
3. `socratic_tutor.py` gestisce il loop domanda → prima risposta → domanda guida (senza svelare la risposta) → seconda risposta → valutazione (0-10, con guardrail di coerenza/severità) → eventuale contestazione del voto.
4. `adaptive_engine.py` tiene traccia dei punteggi per argomento e sceglie la prossima domanda dando priorità agli argomenti deboli.
5. A fine sessione, `report_generator.py` produce un report (Markdown + PDF) salvato su disco e collegato alla sessione nel DB.

3 Decisioni prese nel progetto

Alcune scelte architetturali rilevanti, con la motivazione:

1 **Metodo socratico invece di correzione diretta**
il tutor non dà mai la risposta corretta al primo tentativo: genera sempre una domanda guida. Scelta pedagogica per stimolare il ragionamento invece della memorizzazione passiva.

2 **Embedding locali invece di API esterne**
l'ingestor è partito con API key Gemini per gli embedding ed è stato poi migrato a `sentence-transformers` (`all-MiniLM-L6-v2`) eseguito in locale. Motivazione: nessun costo per chunk indicizzato, funzionamento offline, nessun dato del materiale inviato a terzi solo per vettorizzarlo.

3 **Modello Groq**
Groq ha dismesso Compound il 21 settembre 2026, secondo la comunicazione e-mail del provider; il modello corrente è `openai/gpt-oss-120b`. La chiave `GROQ_API_KEY` e l'autenticazione non sono state sostituite. La relazione del 15 agosto e la cronologia Git consultabile riportano Llama 3.3; l'impiego di Compound è riferito dagli autori.

4 **Retry e rate limit**
Il `NotesGenerator` usa il tempo comunicato da Groq per HTTP 429, con un secondo di margine; se manca, applica backoff esponenziale con jitter fino a 60 secondi. Sono consentite al massimo quattro chiamate complessive.

5 **Guardrail deterministici sopra il giudizio dell'LLM**
`_apply_severity_guardrails` forza il punteggio a 0 se la seconda risposta è una non-risposta ("non so", "boh", ecc.), e `_apply_consistency_guardrails` corregge automaticamente un punteggio insufficiente quando il modello non ha segnalato lacune reali. Motivazione: l'LLM può essere incoerente tra il voto numerico e le motivazioni testuali; queste regole rendono la valutazione riproducibile. *(Presente anche il flag opposto simmetrico: la contestazione del voto usa un secondo agente imparziale — `ContestationAgent` — per rivalutare, non lo stesso agente che ha già giudicato.)*

6 **Isolamento dei dati per studente+esame**
sia la collection ChromaDB (`student_{id}_exam_{id}`) sia le query SQL sono sempre filtrate per `student_id`, così materiali ed esami di studenti diversi non si mescolano mai nel recupero RAG.

7 **Due interfacce parallele (Streamlit diretto + API REST)**
la UI Streamlit non passa dall'API REST: chiama direttamente le funzioni Python degli agenti. L'API REST esiste come strato aggiuntivo, pensato per un consumo esterno futuro (altri client, integrazioni), e replica la stessa logica tramite router FastAPI.

8 **Stato dei tutor/engine attivi in memoria di processo**
`backend/api/sessions.py` tiene `_active_tutors` e `_active_engines` come dizionari in memoria (non persistiti). Implica che un riavvio del server API interrompe le sessioni socratiche in corso: compromesso accettato per semplicità, dato che lo stato definitivo (punteggio, log Q&A) viene comunque scritto su DB alla chiusura di ogni domanda/sessione.

9 **Cookie di sessione persistente lato browser**
`backend/session_cookie.py` genera un token opaco per studente e lo scrive come cookie via componente HTML iniettato, per mantenere il login tra un refresh e l'altro di Streamlit (che altrimenti perderebbe lo stato ad ogni riconnessione websocket).

10 **Pulizia automatica delle sessioni orfane**
sia `sessions.py` (API) sia `history.py` (UI) eliminano/chiudono automaticamente le sessioni avviate ma mai concluse (`ended_at` nullo, nessun punteggio), per non sporcare lo storico con sessioni abbandonate a metà.

4 Tecnologie e librerie usate

Categoria	Scelta	Note
Linguaggio	Python 3.13	`requires-python = ">=3.13"`
Gestione dipendenze	**uv** (`uv.lock`)	con fallback pip
Frontend	**Streamlit** 1.57	UI single-page-per-stato, CSS custom per il tema; cookie persistente via `st.iframe`.
API REST	**FastAPI** 0.136 + Uvicorn	router modulari (auth, exams, sessions), CORS abilitato per `localhost:8501`
ORM / DB	**SQLAlchemy** 2.0 su **SQLite**	`data/study_coach.db`, migrazione leggera in-app per la colonna `session_token`
Validazione dati	**Pydantic** 2.x	schemi richiesta/risposta dell'API (`backend/models/schemas.py`)
Vector store	**ChromaDB** 1.5	`PersistentClient`, una collection per studente+esame
Embedding	**sentence-transformers** (`all-MiniLM-L6-v2`)	locale, 384 dimensioni, nessuna API key
Estrazione PDF	**pypdf**	estrazione testo pagina per pagina
Generazione PDF	**fpdf2**	report sessione e appunti, con layout Markdown→PDF fatto a mano
Agenti LLM	**Agno** + **Groq** `openai/gpt-oss-120b`	agenti specializzati per ruolo: quiz, guida socratica, valutazione, contestazione, dubbi, appunti
Config/segreti	**python-dotenv**	`GROQ_API_KEY` in `.env`; `GROQ_MODEL` facoltativo (default `openai/gpt-oss-120b`); altre chiavi in sezione 6.
Test	**pytest** 9.x + TestClient (FastAPI/httpx) + `streamlit.testing.v1.AppTest`	unit, integration ed e2e (vedi §9 Testing)
Codebase intelligence	**graphify**	grafo del codice usato per l'esplorazione/navigazione del repository durante lo sviluppo, in alternativa alla grep testuale

5 Processo di implementazione

1. **Setup iniziale** — inizializzazione ambiente, modelli DB, primo agente `ingestor` (con API key Gemini per gli embedding).
2. **Motore di dominio** — aggiunta di `quiz_generator`, `socratic_tutor`, `adaptive_engine` e dei template di prompt versionati (`backend/agents/prompts/*_v1.txt`).
3. **Backend "Agno"** — integrazione del framework di agenti Agno con il modello Groq come backend LLM per tutte le generazioni testuali.
4. **Pagine applicative** — costruzione delle pagine Streamlit per la gestione esami e il loop di sessione.
5. **Hardening del tutor socratico** — pulizia delle sessioni non valutate, guardrail di valutazione più severi/coerenti, gestione della durata sessione.
6. **Refactoring e leggibilità** — riorganizzazione della struttura del codice.
7. **Copertura di test** — introduzione di test unitari e di integrazione per gli agenti backend.
8. **Migrazione embedding** — implementazione e configurazione di `LocalEmbeddingFunction` (embedding locali) al posto della sola dipendenza da API esterne.
9. **Chatbot dubbi libero** — nuova classe `DoubtTutor` e pagina `app/pages/chat.py`: flusso socratico avviato dallo studente invece che dal quiz, con due nuovi prompt dedicati.
10. **Suite di test completa** — 157 test tra unit, integration (FastAPI `TestClient`) ed e2e (`streamlit.testing.v1.AppTest`), con isolamento totale da DB/ChromaDB/reports reali tramite fixture pytest dedicate (`test/conftest.py`) e un `FakeAgent` che sostituisce le chiamate LLM reali.

6 Percorsi e configurazione di default

Percorsi su disco (relativi alla root del progetto)

Percorso	Contenuto	Creato da
`data/study_coach.db`	Database SQLite (studenti, esami, materiali, sessioni)	`backend/db/models.py` (`init_db()`)
`data/chroma/`	Vector store ChromaDB persistente	`backend/agents/ingestor.py`
`data/uploads/`	PDF caricati dagli studenti (salvati con prefisso `s{student_id}_e{exam_id}_`)	`backend/api/exams.py`, `app/pages/exam.py`
`reports/`	Report sessione generati (`{student_id}_{exam_id}_{session_id}.md/.pdf`)	`backend/agents/report_generator.py`
`backend/agents/prompts/*.txt`	Template dei prompt per ciascun agente, versionati (`_v1`)	statico, letto a runtime
`graphify-out/`	Grafo del codice generato da graphify (analisi/navigazione repo)	strumento esterno, non parte del runtime applicativo

Variabili d'ambiente (.env)

```
GROQ_API_KEY=...      # obbligatoria
GROQ_MODEL=openai/gpt-oss-120b   # opzionale; default interno
GEMINI_API_KEY=...    # compatibilità/embedding
MISTRAL_API_KEY=...   # opzionale
```

Porte e host di default

Servizio	Comando	Porta di default
Frontend Streamlit	`streamlit run app/main.py`	8501
API REST FastAPI	`uvicorn backend.api.main:app --reload`	8000

Il CORS dell'API è configurato esplicitamente per accettare richieste da `http://localhost:8501` e `http://127.0.0.1:8501` (il frontend Streamlit di default).

> Istruzioni di avvio complete: vedi **AVVIO.md**.

7 Funzionalità implementate

Autenticazione

- Registrazione e login studente (password con hash SHA-256).
- Login persistente tramite cookie: token opaco per studente, letto/scritto/eliminato con `st.iframe` e associato nel DB.
- Logout esplicito con invalidazione del token lato server.

Gestione esami e materiali

- Creazione, rinomina, eliminazione esami.
- Upload di uno o più PDF per esame, con estrazione testo e indicizzazione RAG automatica.
- Visualizzazione dei materiali caricati per esame (pagine, numero di chunk).
- Eliminazione esame → cascata su sessioni/materiali nel DB + rimozione della collection ChromaDB.

Generazione quiz

- Generazione di N domande aperte (3-10) dal materiale indicizzato, su tre livelli di difficoltà (base / intermedia / avanzata), con retry automatico finché il modello non produce un JSON valido e completo.

Tutor socratico (sessione quiz)

- Domanda → prima risposta → domanda guida socratica (mai la risposta corretta) → seconda risposta → valutazione 0-10 con motivazione, punti corretti/mancanti e valutazione del miglioramento.
- Guardrail automatici: punteggio azzerato per non-risposte, punteggio corretto per coerenza quando non sono segnalate lacune reali.
- Contestazione del voto con rivalutazione da parte di un agente imparziale dedicato.

Chatbot dubbi liberi

- Lo studente scrive un dubbio proprio (non legato al quiz) su un argomento del materiale caricato.
- Il tutor risponde con una domanda socratica di apertura (mai la risposta diretta).
- Dopo la risposta dello studente, mostra punti corretti/mancanti e la **risposta corretta e completa** al dubbio originale.
- Interfaccia a chat reale (bolle di conversazione) nella pagina `app/pages/chat.py`.
- Gestione esplicita del caso "nessun materiale pertinente indicizzato".

Motore adattivo

- Tracciamento del punteggio medio per argomento durante la sessione.
- Scelta della prossima domanda con priorità: argomenti deboli → argomenti mai visti → qualunque domanda rimanente.
- Calcolo di argomenti deboli/forti e generazione di un report di sessione aggregato.

Report e appunti

- Report di fine sessione in Markdown e PDF (media, argomenti da rivedere/padroneggiati, verdetto).

- Rigenerazione del PDF a posteriori dallo storico se il file originale manca.
- NotesGenerator: appunti sintetici in Markdown/PDF da contenuti RAG o log di sessione, con focus sulle lacune. Elimina i chunk identici e limita l'output a 2048 token. Il prompt richiede `## Riepilogo`; se manca solo il riepilogo, conserva gli appunti e chiede la sola sezione mancante.

Storico

- Elenco sessioni per esame con statistiche aggregate (media, miglior voto, sessioni completate).
- Dettaglio Q&A per sessione (prima/seconda risposta, domanda guida, motivazione, esito eventuale contestazione).
- Gestione sessioni "orfane" (avviate ma mai concluse): chiusura manuale o eliminazione.
- Download del report PDF e generazione appunti sintetici direttamente dallo storico.

API REST (parallela alla UI)

- Endpoint completi per autenticazione, gestione esami/ingest PDF, ciclo di vita sessione (creazione, generazione quiz, ogni step del tutor socratico, prossima domanda adattiva, chiusura e report, dettaglio/lista sessioni).
- Documentazione automatica OpenAPI su `/docs` e `/redoc`.
- Health check su `/health`.

Qualità e test

- 157 test automatici: unit (logica pura di ogni agente), integration (router FastAPI con DB e ChromaDB isolati), e2e (interazione reale con le pagine Streamlit via AppTest, click sui bottoni compresi).
- Nessuna chiamata LLM reale nei test (FakeAgent dedicato) e nessun dato di test scritto sul DB/ChromaDB/reports reali del progetto.

8 Struttura delle cartelle

```
studycoach/
├── app/                      # Frontend Streamlit
│   ├── main.py               # Entry point, routing tra pagine, CSS globale
│   └── pages/
│       ├── login.py          # Login / registrazione
│       ├── upload.py         # Lista esami, creazione esame
│       ├── exam.py           # Dettaglio esame: avvia sessione, upload PDF, appunti
│       ├── session.py        # Loop quiz + tutor socratico
│       ├── chat.py           # Chatbot dubbi liberi (DoubtTutor)
│       └── history.py        # Storico sessioni, report, appunti
│
├── backend/
│   ├── agents/               # Logica di dominio (indipendente dall'interfaccia)
│   │   ├── ingestor.py           # Estrazione PDF, chunking, embedding, RAG
│   │   ├── quiz_generator.py     # Generazione domande dal materiale
│   │   ├── socratic_tutor.py     # SocraticTutor + DoubtTutor (loop socratico)
│   │   ├── adaptive_engine.py    # Selezione adattiva delle domande, statistiche
│   │   ├── notes_generator.py    # Appunti sintetici (Markdown + PDF)
│   │   ├── report_generator.py   # Report di sessione (Markdown + PDF)
│   │   └── prompts/              # Template dei prompt LLM, versionati
│   ├── api/                  # API REST FastAPI
│   │   ├── main.py           # App FastAPI, CORS, router, health check
│   │   ├── auth.py           # Endpoint autenticazione
│   │   ├── exams.py          # Endpoint esami/ingest
│   │   └── sessions.py       # Endpoint ciclo di vita sessione/tutor
│   ├── db/
│   │   └── models.py         # Modelli SQLAlchemy + inizializzazione DB
│   ├── models/
│   │   └── schemas.py        # Schemi Pydantic per l'API
│   └── session_cookie.py     # Login persistente via cookie browser
│
├── test/                     # Suite di test (unit + integration + e2e)
├── data/                     # DB SQLite, ChromaDB, PDF caricati (runtime, non versionato)
└── reports/                  # Report PDF/Markdown generati (runtime)
```

9 Testing

La suite copre l'intero stack su tre livelli, tutti eseguibili con un unico comando (`pytest`), completamente isolati da dati reali:

Livello	Cosa copre	Come
Unit	Logica degli agenti: guardrail, parsing/riparazione JSON, motore adattivo, pulizia testo/PDF, validatori Pydantic, token di sessione e DB. Test Groq mirati: configurazione/model ID, errori senza secret, parsing Retry-After/backoff, correzione del riepilogo e retry limitati con sleep mockati.	Nessun I/O esterno dove possibile
Integration	Router FastAPI reali (auth, exams, sessions) tramite `TestClient`, incluso upload/ingest di un PDF vero e il flusso completo quiz → tutor → report	DB SQLite temporaneo, collection ChromaDB temporanea con embedding finti deterministici
E2E	Interazione reale con le pagine Streamlit (`app/main.py` e `app/pages/*`) — click sui bottoni, compilazione form, chat — tramite `streamlit.testing.v1.AppTest`	Stesso isolamento DB/ChromaDB, più `FakeAgent` al posto delle chiamate LLM reali

> Fixture condivise in `test/conftest.py` garantiscono che **nessun test scriva mai** sul database, sulla collection ChromaDB o sulla cartella `reports/` reali del progetto.

10 Limitazioni note e possibili sviluppi futuri

- Lo stato dei tutor/engine attivi nell'API REST è **in memoria di processo**: un riavvio del server interrompe le sessioni socratiche in corso (il punteggio già assegnato resta comunque salvato su DB).
- L'estrazione testo dai PDF (`pypdf`) non gestisce PDF scansionati/immagine senza testo selezionabile (nessun OCR).
- L'autenticazione dell'API REST non emette JWT: è pensata per essere consumata dal frontend Streamlit tramite `session_state`; un client esterno andrebbe protetto con un middleware di autenticazione dedicato.
- Sviluppi possibili: persistenza dello stato tutor/engine (es. Redis o tabella dedicata) per sopravvivere ai riavvii; OCR per PDF scansionati; autenticazione JWT per l'API REST pubblica.

11 Divisione dei contributi (Agent)

Come richiesto, di seguito viene indicato esplicitamente quale sviluppatore ha realizzato ciascun agente della cartella `backend/agents/`, in aggiunta alla suddivisione generale già descritta nella sezione 7 (Funzionalità implementate).

Agent (file)	Ruolo nell'agente	Sviluppatore
`ingestor.py`	Estrazione testo dai PDF, chunking (500 parole, overlap 50) ed embedding locale (sentence-transformers); indicizzazione RAG in ChromaDB.	Diabi Mohamed Zakaria
`quiz_generator.py`	Recupero dei chunk più rilevanti (RAG) e generazione di N domande aperte calibrate su tre livelli di difficoltà.	Gouaiche Kamal
`socratic_tutor.py`	Classi SocraticTutor e DoubtTutor: loop domanda → risposta → domanda guida → valutazione, guardrail di coerenza/severità, contestazione del voto.	Diabi Mohamed Zakaria
`adaptive_engine.py`	Tracciamento dei punteggi per argomento e selezione della prossima domanda, con priorità agli argomenti deboli.	Gouaiche Kamal
`notes_generator.py`	Generazione di appunti sintetici (Markdown + PDF) dal materiale caricato o dal log di una sessione già svolta.	Diabi Mohamed Zakaria
`report_generator.py`	Generazione del report di fine sessione (Markdown + PDF): media, argomenti deboli/forti e verdetto.	Gouaiche Kamal

Riepilogo per sviluppatore

Diabi Mohamed Zakaria
`ingestor.py`, `socratic_tutor.py`, `notes_generator.py` (3 agent)

Gouaiche Kamal
`quiz_generator.py`, `adaptive_engine.py`, `report_generator.py` (3 agent)

Gli altri livelli del progetto (frontend Streamlit, API REST, persistenza dati, testing) restano attività condivise tra i due sviluppatori, come già descritto nelle sezioni precedenti.

12 Utilizzo di intelligenza artificiale

Le fasi di lavoro in cui è stata utilizzata l'intelligenza artificiale sono le seguenti:

- **GitHub Copilot (piano Student)** — usato con selezione automatica del modello (autoselect), principalmente per la finalizzazione della parte grafica dell'interfaccia e per l'individuazione di bug ed errori nel codice durante lo sviluppo.
- **Claude (chat)** — usata nella fase iniziale del progetto come supporto per costruire un'idea di massima su come impostare l'applicazione, prima ancora di iniziare a scrivere codice: ci ha aiutato a ragionare sull'architettura generale (suddivisione in frontend, API REST e livello di agenti) e a capire come usare il framework Agno e la libreria Streamlit, due tecnologie non utilizzate in precedenza da noi.