Study Coach

Documentazione di Progetto

Apprendimento socratico su materiale universitario, con RAG

SVILUPPATORI

Diabi Mohamed Zakaria

Gouaiche Kamal

DOCUMENTAZIONE

Progetto e aggiornamenti

Indice

1. Descrizione del progetto 2

2. Architettura del progetto 2

3. Decisioni prese nel progetto 4

4. Tecnologie e librerie usate 5

5. Processo di implementazione 7

6. Percorsi e configurazione di default 8

7. Funzionalità implementate 9

8. Struttura delle cartelle 11

9. Testing 12

10. Limitazioni note e possibili sviluppi futuri 12

11. Divisione dei contributi (Agent) 13

12. Utilizzo di intelligenza artificiale 14

13. Miglioramenti e stato attuale 15

1 Descrizione del progetto

Study Coach è un'applicazione di supporto allo studio universitario che trasforma il materiale didattico (PDF) caricato dallo studente in un percorso di apprendimento interattivo, basato sul **metodo socratico** invece che sulla semplice correzione domanda/risposta.

> **L'idea di fondo:** invece di dare subito la risposta corretta, il sistema fa ragionare lo studente attraverso domande guida, poi mostra dove ha sbagliato e fornisce la risposta corretta e migliorata — il tutto ancorato esclusivamente al materiale caricato (RAG, *Retrieval-Augmented Generation*), per evitare risposte generiche o allucinate.

Il progetto offre due modalità di interazione:

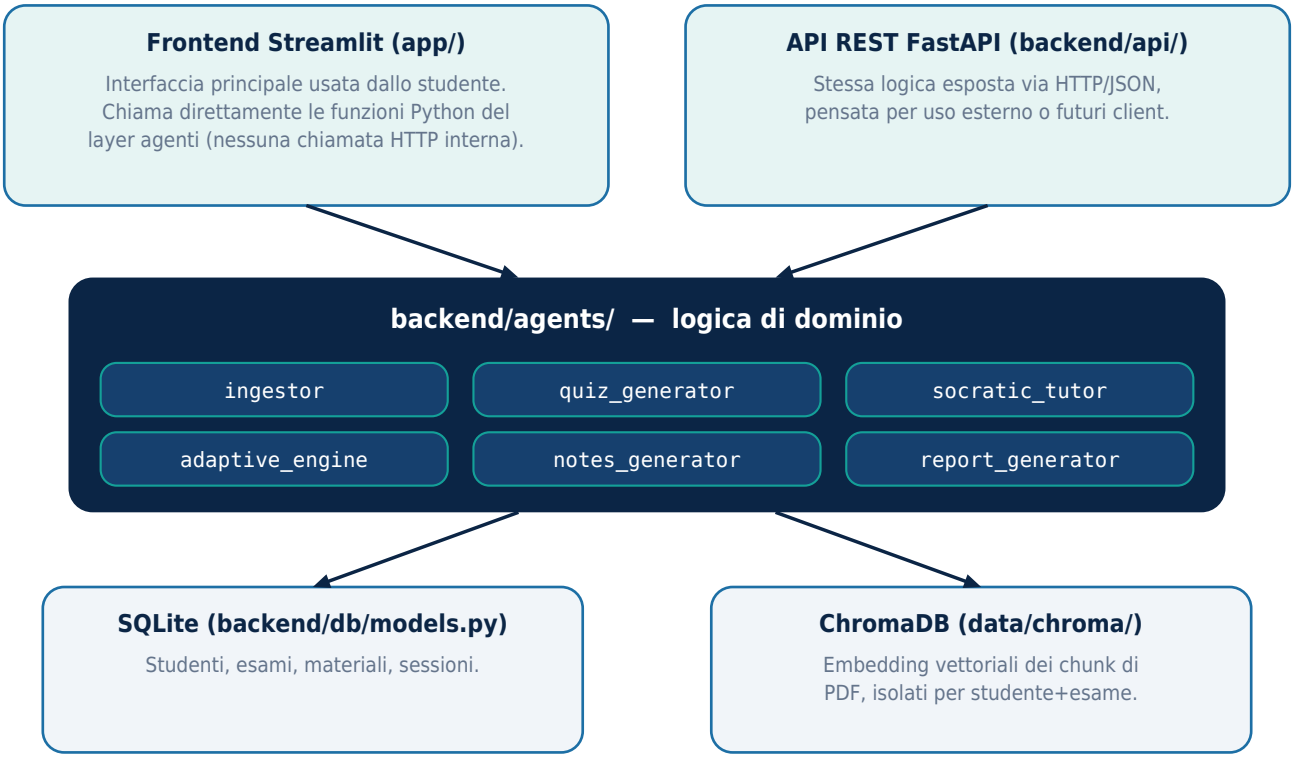
Sessione quiz strutturata
il sistema genera N domande a risposta aperta dal materiale caricato e guida lo studente attraverso ciascuna con il loop socratico.

Chatbot dubbi libero
lo studente scrive un dubbio proprio (non un quiz) e il tutor risponde con una domanda socratica invece di dare subito la soluzione.

Al termine di ogni sessione viene generato un **report** (Markdown + PDF) con punteggio, argomenti deboli/forti e sintesi, e sono disponibili **appunti sintetici** generati dal materiale o dal log della sessione.

2 Architettura del progetto

Il progetto è organizzato in tre macro-livelli, con una netta separazione tra logica di dominio e interfacce:



Componenti principali

> Le chiamate agli agenti Groq sono sincrone e basate su system prompt e contesto del singolo task. Il flusso corrente non configura tool/function calling, ricerca web, esecuzione di codice o cronologia conversazionale.

Livello	Cartella	Ruolo

Frontend	`app/pages/*.py`
	`app/ui.py`
	`app/styles/`
	`.streamlit/config.toml`
		Pagine Streamlit (login, upload, exam, session, chat, history), componenti UI condivisi, stili CSS e configurazione del tema. Chiamano direttamente le funzioni di `backend/agents` — nessuna chiamata HTTP interna.

API REST	`backend/api/*.py`	Router FastAPI (auth, exams, sessions) che espone la stessa logica via HTTP/JSON, con stato dei tutor/engine attivi tenuto in memoria di processo.
Logica di dominio	`backend/agents/*.py`	Agenti indipendenti dall'interfaccia: ingestion RAG, generazione quiz, tutor socratico, motore adattivo, generazione appunti/report. `groq_config.py` centralizza la configurazione del modello Groq.
Persistenza	`backend/db/models.py`	Modelli SQLAlchemy (Student, Exam, Material, Session) su SQLite (`data/study_coach.db`).
Contratti API	`backend/models/schemas.py`	Modelli Pydantic per richieste/risposte dell'API REST.
Login persistente	`backend/session_cookie.py` `backend/session_cookie.js`	Token di sessione lato server (Python) e gestione del cookie lato browser (JavaScript).
Vector store	ChromaDB (`data/chroma/`)	Una collection isolata per ogni coppia student_id+exam_id (`student_{id}_exam_{id}`).

Flusso dati principale

1. Lo studente carica un PDF → `ingestor.py` estrae il testo, lo divide in chunk (500 parole, overlap 50) e li indicizza in ChromaDB con embedding locali.
2. `quiz_generator.py` recupera i chunk più rilevanti (RAG) e chiede a un agente LLM (Groq) di generare N domande aperte, calibrate su tre livelli di difficoltà.
3. `socratic_tutor.py` gestisce il loop domanda → prima risposta → domanda guida (senza svelare la risposta) → seconda risposta → valutazione (0-10, con guardrail di coerenza/severità) → eventuale contestazione del voto.
4. `adaptive_engine.py` tiene traccia dei punteggi per argomento e sceglie la prossima domanda dando priorità agli argomenti deboli.
5. A fine sessione, `report_generator.py` produce un report (Markdown + PDF) salvato su disco e collegato alla sessione nel DB.

3 Decisioni prese nel progetto

Alcune scelte architetturali rilevanti, con la motivazione:

1 **Metodo socratico invece di correzione diretta**
il tutor non dà mai la risposta corretta al primo tentativo: genera sempre una domanda guida. Scelta pedagogica per stimolare il ragionamento invece della memorizzazione passiva.

2 **Embedding locali invece di API esterne**
l'ingestor è partito con API key Gemini per gli embedding ed è stato poi migrato a `sentence-transformers` (`all-MiniLM-L6-v2`) eseguito in locale. Motivazione: nessun costo per chunk indicizzato, funzionamento offline, nessun dato del materiale inviato a terzi solo per vettorizzarlo.

3 **Modello Groq**
Groq ha dismesso Compound il 21 settembre 2026, secondo la comunicazione e-mail del provider; il modello corrente è `openai/gpt-oss-120b`. La chiave `GROQ_API_KEY` e l'autenticazione non sono state sostituite. La relazione del 15 agosto e la cronologia Git consultabile riportano Llama 3.3; l'impiego di Compound è riferito dagli autori. La configurazione del modello (ID e chiave) è raccolta in `backend/agents/groq_config.py`.

4 **Retry e rate limit**
Il `NotesGenerator` usa il tempo comunicato da Groq per HTTP 429, con un secondo di margine; se manca, applica backoff esponenziale con jitter fino a 60 secondi. Sono consentite al massimo quattro chiamate complessive.

5 **Guardrail deterministici sopra il giudizio dell'LLM**
`_apply_severity_guardrails` forza il punteggio a 0 se la seconda risposta è una non-risposta ("non so", "boh", ecc.), e `_apply_consistency_guardrails` corregge automaticamente un punteggio insufficiente quando il modello non ha segnalato lacune reali. Motivazione: l'LLM può essere incoerente tra il voto numerico e le motivazioni testuali; queste regole rendono la valutazione riproducibile. *(Presente anche il flag opposto simmetrico: la contestazione del voto usa un secondo agente imparziale — `ContestationAgent` — per rivalutare, non lo stesso agente che ha già giudicato.)*

6 **Isolamento dei dati per studente+esame**
sia la collection ChromaDB (`student_{id}_exam_{id}`) sia le query SQL sono sempre filtrate per `student_id`, così materiali ed esami di studenti diversi non si mescolano mai nel recupero RAG.

7 **Due interfacce parallele (Streamlit diretto + API REST)**
la UI Streamlit non passa dall'API REST: chiama direttamente le funzioni Python degli agenti. L'API REST esiste come strato aggiuntivo, pensato per un consumo esterno futuro (altri client, integrazioni), e replica la stessa logica tramite router FastAPI.

8 **Stato dei tutor/engine attivi in memoria di processo**
`backend/api/sessions.py` tiene `_active_tutors` e `_active_engines` come dizionari in memoria (non persistiti). Implica che un riavvio del server API interrompe le sessioni socratiche in corso: compromesso accettato per semplicità, dato che lo stato definitivo (punteggio, log Q&A;) viene comunque scritto su DB alla chiusura di ogni domanda/sessione.

9 **Cookie di sessione persistente lato browser**

`backend/session_cookie.py` genera un token opaco per studente; la lettura, scrittura ed eliminazione del cookie nel browser sono affidate allo script `backend/session_cookie.js`, iniettato tramite componente HTML, per mantenere il login tra un refresh e l'altro di Streamlit (che altrimenti perderebbe lo stato ad ogni riconnessione websocket).

10 **Pulizia automatica delle sessioni orfane**

sia `sessions.py` (API) sia `history.py` (UI) eliminano/chiudono automaticamente le sessioni avviate ma mai concluse (`ended_at` nullo, nessun punteggio), per non sporcare lo storico con sessioni abbandonate a metà.

4 Tecnologie e librerie usate

Categoria	Scelta	Note
Linguaggio	Python 3.13	`requires-python = ">=3.13"`
Gestione dipendenze	**uv** (`uv.lock`)	con fallback pip (`requirements.txt`); metadati del progetto in `pyproject.toml`
Frontend	**Streamlit** 1.57	UI single-page-per-stato; stili CSS custom in `app/styles/` (`app.css`, `input.css`), componenti condivisi in `app/ui.py`, tema in `.streamlit/config.toml`; cookie persistente via `st.iframe`.
Tooling JS	**Node.js**	`package.json` / `package-lock.json`: dipendenze JavaScript di sviluppo, usate per il lato JS del progetto (stili e test del client cookie).
API REST	**FastAPI** 0.136 + Uvicorn	router modulari (auth, exams, sessions), CORS abilitato per `localhost:8501`
ORM / DB	**SQLAlchemy** 2.0 su **SQLite**	`data/study_coach.db`, migrazione leggera in-app per la colonna `session_token`
Validazione dati	**Pydantic** 2.x	schemi richiesta/risposta dell'API (`backend/models/schemas.py`)
Vector store	**ChromaDB** 1.5	`PersistentClient`, una collection per studente+esame
Embedding	**sentence-transformers** (`all-MiniLM-L6-v2`)	locale, 384 dimensioni, nessuna API key
Estrazione PDF	**pypdf**	estrazione testo pagina per pagina
Generazione PDF	**fpdf2**	report sessione e appunti, con layout Markdown→PDF fatto a mano

Categoria	Scelta	Note
Agenti LLM	**Agno** + **Groq** `openai/gpt-oss-120b`	agenti specializzati per ruolo: quiz, guida socratica, valutazione, contestazione, dubbi, appunti; configurazione del modello in `groq_config.py`
Config/segreti	**python-dotenv**	`GROQ_API_KEY` in `.env`; `GROQ_MODEL` facoltativo (default `openai/gpt-oss-120b`), letti da `groq_config.py`; altre chiavi in sezione 6.
Test	**pytest** 9.x + TestClient (FastAPI/httpx) + `streamlit.testing.v1.AppTest`; Node.js per il test JS	unit, integration ed e2e (vedi §9 Testing), più un test JavaScript per il client del cookie di sessione

5 Processo di implementazione

1. **Setup iniziale** — inizializzazione ambiente, modelli DB, primo agente `ingestor` (con API key Gemini per gli embedding).
2. **Motore di dominio** — aggiunta di `quiz_generator`, `socratic_tutor`, `adaptive_engine` e dei template di prompt versionati (`backend/agents/prompts/*_v1.txt`).
3. **Backend "Agno"** — integrazione del framework di agenti Agno con il modello Groq come backend LLM per tutte le generazioni testuali.
4. **Pagine applicative** — costruzione delle pagine Streamlit per la gestione esami e il loop di sessione.
5. **Hardening del tutor socratico** — pulizia delle sessioni non valutate, guardrail di valutazione più severi/coerenti, gestione della durata sessione.
6. **Refactoring e leggibilità** — riorganizzazione della struttura del codice.
7. **Copertura di test** — introduzione di test unitari e di integrazione per gli agenti backend.
8. **Migrazione embedding** — implementazione e configurazione di `LocalEmbeddingFunction` (embedding locali) al posto della sola dipendenza da API esterne.
9. **Chatbot dubbi libero** — nuova classe `DoubtTutor` e pagina `app/pages/chat.py`: flusso socratico avviato dallo studente invece che dal quiz, con due nuovi prompt dedicati.
10. **Suite di test completa** — test tra unit, integration (FastAPI `TestClient`) ed e2e (`streamlit.testing.v1.AppTest`), con isolamento totale da DB/ChromaDB/reports reali tramite fixture pytest dedicate (`test/conftest.py`) e un `FakeAgent` che sostituisce le chiamate LLM reali.
11. **Rifinitura del frontend** — introduzione di `app/ui.py`, degli stili in `app/styles/`, del logo (`app/assets/logo.svg`) e della configurazione `.streamlit/config.toml`; cookie di sessione completato con la parte JavaScript (`backend/session_cookie.js`) e relativo test (`session_cookie_client.test.mjs`).

6 Percorsi e configurazione di default

Percorsi su disco (relativi alla root del progetto)

Percorso	Contenuto	Creato da
`data/study_coach.db`	Database SQLite (studenti, esami, materiali, sessioni)	`backend/db/models.py` (`init_db()`)
`data/chroma/`	Vector store ChromaDB persistente	`backend/agents/ingestor.py`
`data/uploads/`	PDF caricati dagli studenti (salvati con prefisso `s{student_id}_e{exam_id}_`)	`backend/api/exams.py`, `app/pages/exam.py`
`reports/`	Report sessione generati (`{student_id}_{exam_id}_{session_id}.md/.pdf`)	`backend/agents/report_generator.py`
`backend/agents/prompts/*.txt`	Template dei prompt per ciascun agente, versionati (`_v1`)	statico, letto a runtime
`.streamlit/config.toml`	Configurazione di Streamlit (tema/impostazioni dell'app)	statico, letto da Streamlit all'avvio
`app/styles/`	Fogli di stile dell'interfaccia (`app.css`, `input.css`)	statico, caricato dal frontend
`AVVIO.md`	Istruzioni di avvio complete	statico, nella root del repository
`pyproject.toml` `requirements.txt` `uv.lock`	Metadati e dipendenze Python	statico, nella root del repository
`package.json` `package-lock.json`	Dipendenze JavaScript (Node.js)	statico, nella root del repository

Variabili d'ambiente (.env)

```
GROQ_API_KEY=...                    # obbligatoria
GROQ_MODEL=openai/gpt-oss-120b      # opzionale; default interno
GEMINI_API_KEY=...                  # compatibilità/embedding
MISTRAL_API_KEY=...                 # opzionale
```

Porte e host di default

Servizio	Comando	Porta di default
Frontend Streamlit	`streamlit run app/main.py`	8501
API REST FastAPI	`uvicorn backend.api.main:app --reload`	8000

Il CORS dell'API è configurato esplicitamente per accettare richieste da `http://localhost:8501` e `http://127.0.0.1:8501` (il frontend Streamlit di default).

> Istruzioni di avvio complete: vedi **AVVIO.md**.

7 Funzionalità implementate

Interfaccia

- Frontend Streamlit con tema e stili personalizzati (`app/styles/`), componenti UI condivisi tra le pagine (`app/ui.py`), logo e configurazione dedicata (`.streamlit/config.toml`).

Autenticazione

- Registrazione e login studente (password con hash SHA-256).
- Login persistente tramite cookie: token opaco per studente generato lato server (`session_cookie.py`), letto/scritto/eliminato nel browser dal client JavaScript (`session_cookie.js`, via `st.iframe`) e associato nel DB.
- Logout esplicito con invalidazione del token lato server.

Gestione esami e materiali

- Creazione, rinomina, eliminazione esami.
- Upload di uno o più PDF per esame, con estrazione testo e indicizzazione RAG automatica.
- Visualizzazione dei materiali caricati per esame (pagine, numero di chunk).
- Eliminazione esame → cascata su sessioni/materiali nel DB + rimozione della collection ChromaDB.

Generazione quiz

- Generazione di N domande aperte (3-10) dal materiale indicizzato, su tre livelli di difficoltà (base / intermedia / avanzata), con retry automatico finché il modello non produce un JSON valido e completo.

Tutor socratico (sessione quiz)

- Domanda → prima risposta → domanda guida socratica (mai la risposta corretta) → seconda risposta → valutazione 0-10 con motivazione, punti corretti/mancanti e valutazione del miglioramento.
- Guardrail automatici: punteggio azzerato per non-risposte, punteggio corretto per coerenza quando non sono segnalate lacune reali.
- Contestazione del voto con rivalutazione da parte di un agente imparziale dedicato.

Chatbot dubbi liberi

- Lo studente scrive un dubbio proprio (non legato al quiz) su un argomento del materiale caricato.

- Il tutor risponde con una domanda socratica di apertura (mai la risposta diretta).
- Dopo la risposta dello studente, mostra punti corretti/mancanti e la **risposta corretta e completa** al dubbio originale.
- Interfaccia a chat reale (bolle di conversazione) nella pagina `app/pages/chat.py`.
- Gestione esplicita del caso "nessun materiale pertinente indicizzato".

Motore adattivo

- Tracciamento del punteggio medio per argomento durante la sessione.
- Scelta della prossima domanda con priorità: argomenti deboli → argomenti mai visti → qualunque domanda rimanente.
- Calcolo di argomenti deboli/forti e generazione di un report di sessione aggregato.

Report e appunti

- Report di fine sessione in Markdown e PDF (media, argomenti da rivedere/padroneggiati, verdetto).
- Rigenerazione del PDF a posteriori dallo storico se il file originale manca.
- NotesGenerator: appunti sintetici in Markdown/PDF da contenuti RAG o log di sessione, con focus sulle lacune. Elimina i chunk identici e limita l'output a 2048 token. Il prompt richiede ## Riepilogo; se manca solo il riepilogo, conserva gli appunti e chiede la sola sezione mancante.

Storico

- Elenco sessioni per esame con statistiche aggregate (media, miglior voto, sessioni completate).
- Dettaglio Q&A; per sessione (prima/seconda risposta, domanda guida, motivazione, esito eventuale contestazione).
- Gestione sessioni "orfane" (avviate ma mai concluse): chiusura manuale o eliminazione.
- Download del report PDF e generazione appunti sintetici direttamente dallo storico.

API REST (parallela alla UI)

- Endpoint completi per autenticazione, gestione esami/ingest PDF, ciclo di vita sessione (creazione, generazione quiz, ogni step del tutor socratico, prossima domanda adattiva, chiusura e report, dettaglio/lista sessioni).
- Documentazione automatica OpenAPI su /docs e /redoc.
- Health check su /health.

Qualità e test

- Suite di test automatici: unit (logica pura di ogni agente), integration (router FastAPI con DB e ChromaDB isolati), e2e (interazione reale con le pagine Streamlit via AppTest, click sui bottoni compresi).
- Test JavaScript dedicato al client del cookie di sessione (`session_cookie_client.test.mjs`).
- Nessuna chiamata LLM reale nei test (FakeAgent dedicato) e nessun dato di test scritto sul DB/ChromaDB/reports reali del progetto.

8 Struttura delle cartelle

```
studycoach/
├── .streamlit/
│   └── config.toml                      # Configurazione di Streamlit
├── app/                                 # Frontend Streamlit
│   ├── assets/
│   │   └── logo.svg                     # Logo dell'applicazione
│   ├── pages/
│   │   ├── login.py                     # Login / registrazione
│   │   ├── upload.py                    # Lista esami, creazione esame
│   │   ├── exam.py                      # Dettaglio esame: avvia sessione, upload PDF, appunti
│   │   ├── session.py                   # Loop quiz + tutor socratico
│   │   ├── chat.py                      # Chatbot dubbi liberi (DoubtTutor)
│   │   └── history.py                   # Storico sessioni, report, appunti
│   ├── styles/
│   │   ├── app.css                      # Stili dell'interfaccia
│   │   └── input.css                    # Sorgente CSS di partenza
│   ├── main.py                          # Entry point, routing tra pagine, CSS globale
│   └── ui.py                            # Componenti/helper UI condivisi tra le pagine
│
├── backend/
│   ├── agents/                          # Logica di dominio (indipendente dall'interfaccia)
│   │   ├── prompts/                     # Template dei prompt LLM, versionati (_v1)
│   │   │   ├── notes_generator_v1.txt
│   │   │   ├── quiz_generator_v1.txt
│   │   │   ├── socratic_tutor_contest_v1.txt
│   │   │   ├── socratic_tutor_doubt_eval_v1.txt
│   │   │   ├── socratic_tutor_doubt_open_v1.txt
│   │   │   ├── socratic_tutor_eval_v1.txt
│   │   │   └── socratic_tutor_guide_v1.txt
│   │   ├── adaptive_engine.py           # Selezione adattiva delle domande, statistiche
│   │   ├── groq_config.py               # Configurazione modello/client Groq
│   │   ├── ingestor.py                  # Estrazione PDF, chunking, embedding, RAG
│   │   ├── notes_generator.py           # Appunti sintetici (Markdown + PDF)
│   │   ├── quiz_generator.py            # Generazione domande dal materiale
│   │   ├── report_generator.py          # Report di sessione (Markdown + PDF)
│   │   └── socratic_tutor.py            # SocraticTutor + DoubtTutor (loop socratico)
│   ├── api/                             # API REST FastAPI
│   │   ├── auth.py                      # Endpoint autenticazione
│   │   ├── exams.py                     # Endpoint esami/ingest
│   │   ├── main.py                      # App FastAPI, CORS, router, health check
│   │   └── sessions.py                  # Endpoint ciclo di vita sessione/tutor
│   ├── db/
│   │   └── models.py                    # Modelli SQLAlchemy + inizializzazione DB
│   ├── models/
│   │   └── schemas.py                   # Schemi Pydantic per l'API
│   ├── session_cookie.js                # Login persistente via cookie (lato browser)
│   └── session_cookie.py                # Login persistente via cookie (lato server)
│
├── test/                                # Suite di test (unit + integration + e2e)
│   ├── conftest.py                      # Fixture condivise e isolamento
│   ├── session_cookie_client.test.mjs   # Test JS del client cookie
│   ├── test_adaptive_engine.py
│   ├── test_api_auth.py
│   ├── test_api_exams.py
│   ├── test_api_main.py
│   ├── test_api_sessions.py
│   ├── test_db_models.py
│   ├── test_e2e_streamlit.py
│   ├── test_groq_config.py
│   ├── test_ingestor.py
│   ├── test_notes_generator.py
│   ├── test_quiz_generator.py
│   ├── test_report_generator.py
│   ├── test_schemas.py
│   ├── test_session_cookie.py
│   └── test_socratic_tutor.py
│
├── data/                                # DB SQLite, ChromaDB, PDF caricati (runtime, non versionato)
├── reports/                             # Report PDF/Markdown generati (runtime)
├── AVVIO.md                             # Istruzioni di avvio complete
├── Study_Coach_Documentazione.pdf       # Questa documentazione
├── package.json
├── package-lock.json
├── pyproject.toml
├── requirements.txt
└── uv.lock
```

9 Testing

La suite Python copre l'intero stack su tre livelli, tutti eseguibili con un unico comando (`pytest`) e completamente isolati da dati reali. Il client JavaScript del cookie di sessione ha un test separato, eseguito con Node.js:

Livello	Cosa copre	Come
Unit	Logica degli agenti: guardrail, parsing/riparazione JSON, motore adattivo, pulizia testo/PDF, validatori Pydantic, token di sessione (`test_session_cookie.py`) e DB. Test Groq mirati (`test_groq_config.py`): configurazione/model ID, errori senza secret, parsing Retry-After/backoff, correzione del riepilogo e retry limitati con sleep mockati.	Nessun I/O esterno dove possibile
Integration	Router FastAPI reali (auth, exams, sessions) tramite `TestClient`, incluso upload/ingest di un PDF vero e il flusso completo quiz → tutor → report	DB SQLite temporaneo, collection ChromaDB temporanea con embedding finti deterministici
E2E	Interazione reale con le pagine Streamlit (`app/main.py` e `app/pages/*`) — click sui bottoni, compilazione form, chat — tramite `streamlit.testing.v1.AppTest`	Stesso isolamento DB/ChromaDB, più `FakeAgent` al posto delle chiamate LLM reali
JavaScript	Client JS del cookie di sessione (`backend/session_cookie.js`), testato in `test/session_cookie_client.test.mjs`	Eseguito con Node.js, separatamente da pytest

> Fixture condivise in `test/conftest.py` garantiscono che **nessun test scriva mai** sul database, sulla collection ChromaDB o sulla cartella `reports/` reali del progetto.

10 Limitazioni note e possibili sviluppi futuri

- Lo stato dei tutor/engine attivi nell'API REST è **in memoria di processo**: un riavvio del server interrompe le sessioni socratiche in corso (il punteggio già assegnato resta comunque salvato su DB).
- L'estrazione testo dai PDF (`pypdf`) non gestisce PDF scansionati/immagine senza testo selezionabile (nessun OCR).
- L'autenticazione dell'API REST non emette JWT: è pensata per essere consumata dal frontend Streamlit tramite `session_state`; un client esterno andrebbe protetto con un middleware di autenticazione dedicato.
- Sviluppi possibili: persistenza dello stato tutor/engine (es. Redis o tabella dedicata) per sopravvivere ai riavvii; OCR per PDF scansionati; autenticazione JWT per l'API REST pubblica.

11 Divisione dei contributi (Agent)

Come richiesto, di seguito viene indicato esplicitamente quale sviluppatore ha realizzato ciascun agente della cartella `backend/agents/`, in aggiunta alla suddivisione generale già descritta nella sezione 7 (Funzionalità implementate).

Agent (file)	Ruolo nell'agente	Sviluppatore
`ingestor.py`	Estrazione testo dai PDF, chunking (500 parole, overlap 50) ed embedding locale (sentence-transformers); indicizzazione RAG in ChromaDB.	Diabi Mohamed Zakaria
`quiz_generator.py`	Recupero dei chunk più rilevanti (RAG) e generazione di N domande aperte calibrate su tre livelli di difficoltà.	Gouaiche Kamal
`socratic_tutor.py`	Classi SocraticTutor e DoubtTutor: loop domanda → risposta → domanda guida → valutazione, guardrail di coerenza/severità, contestazione del voto.	Diabi Mohamed Zakaria
`adaptive_engine.py`	Tracciamento dei punteggi per argomento e selezione della prossima domanda, con priorità agli argomenti deboli.	Gouaiche Kamal
`notes_generator.py`	Generazione di appunti sintetici (Markdown + PDF) dal materiale caricato o dal log di una sessione già svolta.	Diabi Mohamed Zakaria
`report_generator.py`	Generazione del report di fine sessione (Markdown + PDF): media, argomenti deboli/forti e verdetto.	Gouaiche Kamal

Riepilogo per sviluppatore

Diabi Mohamed Zakaria

`ingestor.py`, `socratic_tutor.py`, `notes_generator.py` (3 agent)

Gouaiche Kamal

`quiz_generator.py`, `adaptive_engine.py`, `report_generator.py` (3 agent)

Gli altri livelli del progetto (frontend Streamlit, API REST, persistenza dati, testing) restano attività condivise tra i due sviluppatori, come già descritto nelle sezioni precedenti.

12 Utilizzo di intelligenza artificiale

Le fasi di lavoro in cui è stata utilizzata l'intelligenza artificiale sono le seguenti:

- **GitHub Copilot (piano Student)** — usato con selezione automatica del modello (autoselect), principalmente per la finalizzazione della parte grafica dell'interfaccia e per l'individuazione di bug ed errori nel codice durante lo sviluppo.
- **Claude (chat)** — usata nella fase iniziale del progetto come supporto per costruire un'idea di massima su come impostare l'applicazione, prima ancora di iniziare a scrivere codice: ci ha aiutato a ragionare sull'architettura generale (suddivisione in frontend, API REST e livello di agenti) e a capire come usare il framework Agno e la libreria Streamlit, due tecnologie non utilizzate in precedenza da noi.

13 Miglioramenti e stato attuale

Questa sezione riunisce gli interventi che completano o aggiornano le funzionalità descritte nelle sezioni precedenti. Ogni area distingue il comportamento implementato dalle verifiche disponibili e dai limiti ancora presenti.

13.1 Materiali e recupero delle fonti

L'ingestione assegna a ogni chunk un identificativo derivato dall'hash SHA-256 del documento, dalla pagina e dalla posizione, evitando collisioni tra PDF dello stesso esame. Il caricamento controlla firma e dimensione del file, usa un nome interno univoco e tenta l'OCR quando una pagina non contiene testo estraibile. Le statistiche distinguono pagine totali, pagine con testo e pagine scartate.

La verifica dell'indice confronta file, record dei materiali e chunk presenti in ChromaDB, segnalando contenuti mancanti o orfani. La reindicizzazione conserva una copia dei chunk precedenti: se l'elaborazione o il salvataggio fallisce, elimina i nuovi chunk parziali e ripristina lo stato precedente. Un errore del vector store è distinto da una ricerca senza risultati.

I materiali scelti dallo studente sono salvati nella sessione e limitano il retrieval del quiz, del tutor e degli appunti generati dal log. Le domande del quiz devono contenere una citazione letterale verificata sui passaggi indicizzati; la generazione è suddivisa in contesti limitati e l'eventuale recupero di domande incomplete usa soltanto contesti fondati.

13.2 Tutor, giudizi e adattamento

Il tutor mantiene il percorso socratico: prima risposta, domanda guida, seconda risposta e valutazione motivata. I guardrail distinguono le non-risposte dalle risposte miste, evitando azzeramenti indebiti; un campo missing_points assente non equivale a una lista vuota dichiarata dal modello. La contestazione usa un agente separato e controlla struttura e limiti dell'esito.

Il validatore verifica tipi, campi e coerenza interna del giudizio. Se la risposta del modello resta non valida dopo i tentativi previsti, il giudizio viene marcato reliable=False. Un punteggio numerico non affidabile rimane visibile e contribuisce alla media descrittiva del report, ma non viene usato dal motore adattivo per scegliere le domande successive.

Questi controlli non provano da soli che i punti corretti siano realmente nella risposta dello studente, che i punti mancanti siano nel materiale o che la motivazione giustifichi sempre il voto. La fedeltà semantica resta un limite da valutare con un riferimento umano.

13.3 Sessioni, interfaccia ed esportazioni

L'interfaccia operativa è realizzata con FastAPI, template Jinja e JavaScript; sostituisce il precedente frontend Streamlit. API e pagine web condividono la logica degli agenti. Un router configura separatamente i provider LLM per quiz, tutor e appunti, con fallback dove previsto. Gli embedding locali usano un modello multilingue; la compatibilità delle collection esistenti viene controllata tramite metadati.

Quiz, turno corrente, risposte, valutazioni e tempo attivo sono persistiti in SQLite. Una sessione può essere messa in pausa e ripresa senza affidarsi allo stato in memoria del processo; le conversazioni sui dubbi sono archiviate. Una sessione non attiva non può avviare un nuovo turno.

Report e appunti sono scaricabili in Markdown e PDF. Gli appunti possono partire dal materiale selezionato o dal log della sessione; la generazione applica controlli strutturali e una revisione prima dell'esportazione.

13.4 Sicurezza, configurazione ed errori

Area	Comportamento implementato
Accesso	Password con bcrypt; cookie di autenticazione HTTP-only; verifica dell'appartenenza di esami, materiali e sessioni allo studente.
Upload	Firma e dimensione del PDF controllate; nome di archiviazione univoco; errori di ingestione classificati.
Origini web	CORS configurabile senza origini esterne abilitate per impostazione predefinita; controllo dell'origine sui flussi web di modifica.
Provider	Limiti di quota riconosciuti dallo stato HTTP, tentativi limitati e messaggio finale esplicito.
Configurazione	Dimensione dei chunk e limiti dei contesti di quiz e appunti configurabili tramite variabili d'ambiente documentate.

Un identificativo di richiesta collega i log delle fasi principali. Il tracciamento registra durata, modello e numero di passaggi recuperati senza includere testo dello studente nei nuovi eventi. Non è una piattaforma completa di tracing distribuito.

13.5 Verifica e limiti

I test automatizzati coprono agenti, API, ingestione multi-PDF, controllo dell'indice, rollback, selezione delle fonti, ripresa delle sessioni, valutazioni e report. Per riproducibilità, la suite ordinaria sostituisce LLM ed embedding con implementazioni controllate; dimostra il comportamento del software nelle condizioni simulate, non la qualità generale dei modelli.

Un insieme separato di casi valuta direttamente il modello reale su materiali di riferimento, voti e citazioni. Questa prova non attraversa l'intera applicazione web. Il confronto con giudizi umani motivati, la stabilità su più esecuzioni e i test end-to-end con provider reale restano aspetti da ampliare.

Limite residuo	Conseguenza
Fedeltà del modello	Citazioni e validatori riducono errori specifici, ma non garantiscono correttezza di ogni spiegazione o voto.
Prompt injection	I passaggi recuperati sono trattati come dati e alcuni tentativi di impersonare istruzioni di sistema sono intercettati; la copertura non è generale.
Guasti distribuiti	Il ripristino dell'indice è testato con sostituti controllati; manca una prova di guasto multi-processo con servizi reali.
Qualità dei PDF	L'OCR amplia i materiali leggibili, ma l'accuratezza dipende dalla qualità della scansione.